

PROFEVIXO • GUÍA DE ESTUDIO

Estadística matemática

Estimadores, suficiencia y máxima verosimilitud.

Probabilidad y estadística

Univ 3-4

20 EJERCICIOS

TEORÍA + RESULTADOS

Estadística matemática: guía simple

La estadística matemática estudia cómo **estimar** (adivinar con reglas) los números desconocidos de una población a partir de una muestra, y cómo medir qué tan buenas son esas adivinanzas.

Conceptos básicos

- **Población:** el conjunto completo que interesa (ej. todos los estudiantes).
- **Muestra:** los datos observados $X_1, X_2, \dots, X_n$ (ej. 200 estudiantes medidos).
- **Parámetro:** el número desconocido de la población, denotado θ (ej. la media μ , la proporción p).
- **Estimador:** la fórmula que adivina el parámetro con los datos, denotada $\hat{\theta}$. Es una variable aleatoria: cambia de muestra en muestra.
- **Estimación:** el número concreto que sale al aplicar la fórmula a los datos observados.

Propiedades de los estimadores

- **Insesgado:** en promedio acierta: $E[\hat{\theta}] = \theta$. El **sesgo** es $E[\hat{\theta}] - \theta$.
- **Consistente:** con más datos se acerca al valor verdadero: $\hat{\theta} \xrightarrow{P} \theta$.
- **Eficiente:** entre los insesgados, tiene la varianza mínima posible.
- **Error cuadrático medio (ECM):** combina ambos: $\text{ECM} = \text{Var}(\hat{\theta}) + (\text{sesgo})^2$.

Ejemplo clave: la varianza muestral con $n - 1$, $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$, es insesgada para σ^2 ; con n tiene sesgo $-\sigma^2/n$.

Suficiencia

Un estadístico T es **suficiente** para θ si contiene toda la información de la muestra sobre θ . **Criterio de factorización:** la verosimilitud se descompone como

$$L(\theta; x) = g(T(x), \theta) \cdot h(x)$$

Suficientes clásicos: $\bar{X}$ para μ normal; $\sum X_i$ para Poisson; $\max X_i$ para uniforme $(0, \theta)$. El **teorema de Rao-Blackwell** mejora cualquier estimador insesgado condicionándolo en un estadístico suficiente: $E[\hat{\theta} | T]$ tiene varianza menor o igual.

Máxima verosimilitud (MV)

Se elige el valor de θ que hace más probable lo observado. La **función de verosimilitud** es la probabilidad conjunta de los datos:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

Método: 1) escribir L ; 2) tomar $\ln L$ (el logaritmo convierte el producto en suma); 3) derivar respecto a θ e igualar a cero; 4) verificar máximo con la segunda derivada.

Resultados que debes saber: Bernoulli $\hat{p} = \bar{X}$; Poisson $\hat{\lambda} = \bar{X}$; normal $\hat{\mu} = \bar{X}$ y $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (sesgado, usa n); exponencial $\hat{\lambda} = 1/\bar{X}$; uniforme $(0, \theta)$ $\hat{\theta} = \max X_i$.

Método de momentos

Iguala momentos teóricos con empíricos y despeja:

$$E[X^k] = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Ejemplos: exponencial $\hat{\lambda} = 1/\bar{X}$; uniforme $(0, \theta)$ $\hat{\theta} = 2\bar{X}$; Poisson $\hat{\lambda} = \bar{X}$. Simple, pero a veces menos eficiente que MV e incluso da valores imposibles (como $2\bar{X} < \max X_i$ en la uniforme).

Cota de Cramér-Rao e información de Fisher

La **información de Fisher** mide cuánta información aporta una observación sobre θ :

$$I(\theta) = E \left[\left(\frac{\partial \ln f}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln f}{\partial \theta^2} \right]$$

Para todo estimador insesgado, la varianza no puede bajar de la **cota de Cramér-Rao**:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{n I(\theta)}$$

Un estimador que la alcanza es **eficiente**. Valores útiles: Bernoulli $I(p) = \frac{1}{p(1-p)}$; Poisson $I(\lambda) = 1/\lambda$; exponencial $I(\lambda) = 1/\lambda^2$; normal (para μ , con σ conocida) $I(\mu) = 1/\sigma^2$. Ojo: si el dominio depende del parámetro (uniforme), la cota puede no valer.

Intervalos y pruebas óptimas

- **Pivote**: cantidad cuya distribución no depende del parámetro; de ella se despeja el intervalo. Por ejemplo $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$ da el IC $\bar{X} \pm t^* S/\sqrt{n}$.
- **Neyman-Pearson**: la prueba más potente de nivel α entre hipótesis simples rechaza cuando $\frac{L(\theta_1)}{L(\theta_0)} > c$.
- **Razón de verosimilitud (LR)**: para hipótesis compuestas, $\Lambda = \frac{\sup_{H_0} L(\theta)}{\sup_{\Theta} L(\theta)}$; bajo H_0 , $-2 \ln \Lambda \sim \chi_k^2$ (teorema de Wilks), con k = parámetros restringidos.

Bootstrap y jackknife

- **Bootstrap**: remuestra B veces **con reposición** de los datos observados, recalcula el estadístico en cada remuestra y usa esa variabilidad para estimar error estándar, sesgo e intervalos (percentiles 2.5 y 97.5). No necesita supuestos paramétricos.
- **Jackknife**: deja **un dato fuera** a la vez, formando n sub-muestras; estima sesgo y varianza. Con datos dependientes (series), el bootstrap debe remuestrear bloques.

Ejercicios (20)

Nivel 1 — fundamentos

- 1 Halla el estimador de máxima verosimilitud de p en una muestra Bernoulli de tamaño n .
- 2 Halla el MV de λ en una muestra Poisson.
- 3 ¿Es $\bar{X}$ un estimador insesgado de la media μ ?
- 4 ¿Cuál es el sesgo de $\frac{1}{n} \sum (X_i - \bar{X})^2$ como estimador de σ^2 ?
- 5 Da un estadístico suficiente para p en una muestra Bernoulli.

Nivel 2 — verosimilitud y momentos

- 6 Halla el MV de λ en una muestra exponencial.
- 7 Halla el MV de σ^2 para una normal con μ desconocida.
- 8 Halla el estimador de momentos de θ para una uniforme $(0, \theta)$.
- 9 Calcula la información de Fisher de una observación Bernoulli.
- 10 Calcula la cota de Cramér-Rao para $\hat{\lambda}$ en una muestra Poisson.

Nivel 3 — eficiencia y Fisher

- 11 Halla el MV de θ para la uniforme $(0, \theta)$ y explica por qué no se deriva.
- 12 Demuestra con la factorización que $\max X_i$ es suficiente para la uniforme $(0, \theta)$.
- 13 Calcula la información de Fisher de la exponencial y su cota.
- 14 Calcula la información de Fisher para μ de una normal con σ conocida y la cota.
- 15 Un estimador tiene varianza 4 y sesgo 1. Halla su ECM.

Nivel 4 — teoría fina

- 16 Si $E[\max X_i] = \frac{n}{n+1}\theta$ para la uniforme $(0, \theta)$, construye un estimador insesgado de θ a partir del máximo.

- 17 Según el teorema de Wilks, ¿qué distribución tiene $-2 \ln \Lambda$ bajo H_0 ?
- 18 ¿Qué prueba es la más potente entre las de nivel α según el lema de Neyman-Pearson?
- 19 ¿Cómo construye el bootstrap una muestra bootstrap a partir de $x_1, \dots, x_n$?
- 20 ¿Qué hace el jackknife con una muestra de n datos y para qué sirve?

Respuestas

- 1 $\hat{p} = \bar{X} = \frac{1}{n} \sum X_i$ (la frecuencia de éxitos).
- 2 $\hat{\lambda} = \bar{X}$.
- 3 Sí: $E[\bar{X}] = \mu$.
- 4 Sesgo $= -\sigma^2/n$ (se queda corto; por eso se usa $n - 1$).
- 5 $T = \sum_{i=1}^n X_i$ (o equivalentemente $\bar{X}$).
- 6 $\hat{\lambda} = 1/\bar{X}$.
- 7 $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (con n , ligeramente sesgado).
- 8 $E[X] = \theta/2 = \bar{X} \Rightarrow \hat{\theta} = 2\bar{X}$.
- 9 $I(p) = \frac{1}{p(1-p)}$.
- 10 Cota $= \lambda/n$ (pues $I(\lambda) = 1/\lambda$), alcanzada por $\bar{X}$.
- 11 $\hat{\theta} = \max X_i$; no se deriva porque la verosimilitud θ^{-n} es monótona decreciente en θ y el máximo está en la frontera admisible.
- 12 $L(\theta) = \theta^{-n} \mathbb{1}_{\{x_{(n)} \leq \theta\}}$ depende de los datos solo a través de $x_{(n)} = \max x_i$: factoriza con $g = \theta^{-n} \mathbb{1}_{\{T \leq \theta\}}$, $h = 1$.
- 13 $I(\lambda) = 1/\lambda^2$; cota $= \lambda^2/n$.
- 14 $I(\mu) = 1/\sigma^2$; cota $= \sigma^2/n$, alcanzada por $\bar{X}$.

15 $ECM = \text{Var} + \text{sesgo}^2 = 4 + 1 = 5$.

16 $\hat{\theta} = \frac{n+1}{n} \max X_i$ (multiplicar por $(n+1)/n$ corrige el sesgo).

17 χ_k^2 (ji-cuadrado con k = número de parámetros restringidos por H_0), asintóticamente.

18 La que compara el cociente de verosimilitudes $L(\theta_1)/L(\theta_0)$ contra una constante c elegida para el nivel α .

19 Toma n valores al azar de $x_1, \dots, x_n$ **con reposición** (pueden repetirse), repite B veces y calcula el estadístico en cada remuestra.

20 Deja un dato fuera a la vez (forma n sub-muestras de $n - 1$ datos) y usa los n valores del estadístico para estimar sesgo y varianza.