

PROFEVIXO • GUÍA DE ESTUDIO

Estadística matemática

Estimadores, suficiencia y máxima verosimilitud.

Probabilidad y estadística

Univ 3-4

20 EJERCICIOS

TEORÍA + RESULTADOS

Estadística matemática

Guía simple · Probabilidad y estadística · Univ 3–4 *Estimadores, suficiencia y máxima verosimilitud.*

1. Estimadores y sus propiedades

Un **estimador** $\hat{\theta}$ es una función de la muestra $X_1, \dots, X_n$ que aproxima un parámetro θ desconocido. Sus propiedades se miden así:

- **Sesgo:** $\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta$. El estimador es **insesgado** si $E[\hat{\theta}] = \theta$.
- **Varianza:** $\text{Var}(\hat{\theta})$ mide la dispersión del estimador alrededor de su media.
- **Error cuadrático medio:** $\text{ECM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Sesgo}(\hat{\theta})^2$.
- **Consistencia:** $\hat{\theta} \rightarrow \theta$ en probabilidad cuando $n \rightarrow \infty$.
- **Eficiencia:** entre los insesgados, alcanza la menor varianza posible (idealmente la cota de Cramér–Rao).

Estimadores notables:

1 $\bar{X}$ es insesgado y consistente para μ .

2 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ es insesgado para σ^2 (de ahí el $n - 1$).

3 $S_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ tiene sesgo $-\sigma^2/n$.

Mini-ejemplo. Si $E[X] = \mu$ y $\text{Var}(X) = \sigma^2$, entonces $\text{Var}(\bar{X}) = \sigma^2/n$ y $\text{ECM}(\bar{X}) = \sigma^2/n$.

2. Suficiencia y criterio de Neyman–Fisher

Un estadístico $T(X_1, \dots, X_n)$ es **suficiente** para θ si conserva toda la información de la muestra sobre θ ; equivalentemente, la distribución condicional de los datos dado T no depende de θ .

Criterio de factorización (Neyman–Fisher). T es suficiente para θ si y solo si la verosimilitud factoriza como

$$L(\theta; x) = g(T(x), \theta) h(x)$$

donde $h(x)$ no depende de θ .

Suficientes típicos:

1 Normal con σ conocida: $T = \sum X_i$ (o $\bar{X}$) para μ .

2 Poisson: $T = \sum X_i$ para λ .

3 Uniforme(0, θ): $T = \max X_i$ para θ .

4 Bernoulli: $T = \sum X_i$ para p .

5 Normal con μ conocido: $T = \sum (X_i - \mu)^2$ para σ^2 .

Teorema de Rao–Blackwell. Si $\hat{\theta}$ es insesgado y T es suficiente, entonces $E[\hat{\theta} | T]$ es insesgado para θ y tiene varianza menor o igual que $\hat{\theta}$.

Mini-ejemplo. En Bernoulli, $1_{X_1=1}$ es insesgado para p ; condicionando en $T = \sum X_i$ se obtiene $\bar{X}$, con menor varianza.

3. Estimación por máxima verosimilitud

La **verosimilitud** de una muestra iid es

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta), \quad \ell(\theta) = \ln L(\theta)$$

y el **estimador de máxima verosimilitud (MV)** es

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(\theta).$$

Procedimiento:

1 Escribe la verosimilitud como producto de densidades (o masas).

2 Toma logaritmo para convertir el producto en suma.

3 Deriva respecto de θ , iguala a cero y resuelve la **ecuación de verosimilitud**.

4 Verifica que es un máximo (segunda derivada o borde del dominio).

Casos básicos:

1 Bernoulli/Binomial: $\hat{p} = \bar{X}$.

2 Poisson: $\hat{\lambda} = \bar{X}$.

3 Exponencial: $\hat{\lambda} = 1/\bar{X}$.

4 Normal: $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (sesgado).

5 Uniforme(0, θ): $\hat{\theta} = \max X_i$.

Propiedades. Bajo regularidad, el MV es consistente, asintóticamente normal con varianza $(n I(\theta))^{-1}$ y asintóticamente eficiente; en muestras finitas puede estar sesgado. **Invariancia:** si $\hat{\theta}$ es MV de θ , entonces $g(\hat{\theta})$ es MV de $g(\theta)$.

Mini-ejemplo. Para Bernoulli, $\ell(p) = \sum x_i \ln p + (n - \sum x_i) \ln(1 - p)$; derivando, $\hat{p} = \bar{X}$.

4. Método de momentos

Iguala los **momentos poblacionales** con los **momentos muestrales**:

$$E[X^k] = \frac{1}{n} \sum_{i=1}^n X_i^k$$

y resuelve el sistema para los parámetros. Con r parámetros se usan $k = 1, \dots, r$.

Mini-ejemplo. Uniforme(0, θ): como $E[X] = \theta/2$, igualando $\bar{X} = \theta/2$ resulta $\hat{\theta} = 2\bar{X}$.

Ventajas y límites. Es simple y no requiere optimización, pero suele ser menos eficiente que MV y puede producir valores fuera del rango del parámetro. En la uniforme(0, θ), MV da $\max X_i$, que es mejor que $2\bar{X}$.

5. Información de Fisher y cota de Cramér–Rao

La **información de Fisher** de una observación es

$$I(\theta) = E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right].$$

Para una muestra iid la información total es $n I(\theta)$.

Cota de Cramér–Rao. Bajo condiciones de regularidad, todo estimador insesgado cumple

$$\text{Var}(\hat{\theta}) \geq \frac{1}{n I(\theta)}.$$

Un estimador que alcanza la cota es **eficiente**. La MV suele alcanzarla solo asintóticamente.

Ejemplos:

1 Normal con σ conocida: $I(\mu) = 1/\sigma^2$; cota σ^2/n (alcanzada por $\bar{X}$).

2 Bernoulli: $I(p) = \frac{1}{p(1-p)}$; cota $p(1-p)/n$.

3 Poisson: $I(\lambda) = 1/\lambda$; cota λ/n .

4 Exponencial: $I(\lambda) = 1/\lambda^2$; cota λ^2/n .

Advertencia. Si el soporte de f depende de θ (por ejemplo $\text{uniforme}(0, \theta)$), falla la regularidad y la cota no es aplicable.

6. Pruebas óptimas: Neyman–Pearson y razón de verosimilitud

Lema de Neyman–Pearson. Para $H_0 : \theta = \theta_0$ frente a $H_1 : \theta = \theta_1$, la prueba más potente de nivel α rechaza la hipótesis nula cuando

$$\frac{L(\theta_1; x)}{L(\theta_0; x)} > k$$

eligiendo la constante k tal que $P(\text{rechazar} \mid H_0) = \alpha$.

Razón de verosimilitud (LR). Para hipótesis compuestas se usa

$$\Lambda = \frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta} L(\theta)}, \quad 0 \leq \Lambda \leq 1.$$

Teorema de Wilks. Bajo H_0 y condiciones de regularidad, $-2 \ln \Lambda$ converge en distribución a una χ^2 con grados de libertad iguales a la diferencia de parámetros libres. Es la base de los contrastes de modelos anidados.

Mini-ejemplo. Normal con σ conocida y $H_0 : \mu = \mu_0$: $-2 \ln \Lambda = z^2$ con $z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$, que sigue una χ_1^2 .

7. Métodos computacionales: bootstrap y jackknife

Bootstrap. Aproxima la distribución muestral de un estadístico remuestreando con reposición de los datos observados:

- 1 Genera B muestras bootstrap de tamaño n (con reposición).
- 2 Calcula $\hat{\theta}_b^*$ en cada muestra.
- 3 Usa la variabilidad de $\{\hat{\theta}_b^*\}$ para estimar el sesgo, el error estándar y los intervalos de confianza (por percentiles).

Jackknife. Deja fuera una observación a la vez, calcula $\hat{\theta}_{(i)}$ y estima el sesgo como

$$\widehat{\text{Sesgo}}_{jack} = (n-1)(\bar{\hat{\theta}}_{(\cdot)} - \hat{\theta}),$$

donde $\bar{\hat{\theta}}_{(\cdot)}$ es el promedio de los estimadores dejando uno fuera.

Ventajas. Ambos funcionan cuando la teoría asintótica es dudosa o la distribución exacta es intratable (mediana, correlación, cocientes). Para datos dependientes se requiere bootstrap por bloques.

Ejercicios (20)

Nivel 1 — Estimadores y propiedades

- 1 ¿Es $\bar{X}$ insesgado para μ ?
- 2 Halla el sesgo de $S_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ para σ^2 .
- 3 Calcula $\text{ECM}(\bar{X})$ para μ si $\text{Var}(X) = \sigma^2$.
- 4 ¿Es $2\bar{X}$ insesgado para θ en $\text{uniforme}(0, \theta)$?
- 5 Si un estimador tiene $\text{Var} = \sigma^2/n$ y sesgo b , escribe su ECM.

Nivel 2 — Suficiencia y máxima verosimilitud

- 6 Da un estadístico suficiente para λ en $\text{Poisson}(\lambda)$.
- 7 Da un estadístico suficiente para θ en $\text{uniforme}(0, \theta)$.
- 8 Halla el MV de p en $\text{Bernoulli}(p)$.
- 9 Halla el MV de λ en $\text{exponencial}(\lambda)$.
- 10 Halla el MV de σ^2 en normal con μ desconocido.

Nivel 3 — Fisher, Cramér–Rao y momentos

- 11 Halla $I(\mu)$ para normal con σ conocida.
- 12 Halla $I(p)$ para $\text{Bernoulli}(p)$.
- 13 Da la cota de Cramér–Rao para λ en Poisson.
- 14 Halla el estimador de momentos de θ en $\text{uniforme}(0, \theta)$.
- 15 Da la cota de Cramér–Rao para μ con $n = 10$ y $\sigma = 2$.

Nivel 4 — Pruebas óptimas y métodos computacionales

- 16 ¿Qué cociente compara la prueba más potente según Neyman–Pearson?

17 ¿Cuál es la distribución asintótica de $-2 \ln \Lambda$ bajo H_0 ?

18 ¿Qué distribución aproxima el bootstrap?

19 ¿Qué estima el jackknife?

20 Si $\beta = 0.20$, ¿cuál es la potencia?

Respuestas

1 Sí.

2 $-\sigma^2/n$.

3 σ^2/n .

4 Sí, porque $E[2\bar{X}] = 2(\theta/2) = \theta$.

5 $\sigma^2/n + b^2$.

6 $T = \sum X_i$.

7 $T = \max X_i$.

8 $\hat{p} = \bar{X}$.

9 $\hat{\lambda} = 1/\bar{X}$.

10 $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$.

11 $I(\mu) = 1/\sigma^2$.

12 $I(p) = \frac{1}{p(1-p)}$.

13 λ/n .

14 $\hat{\theta} = 2\bar{X}$.

15 $\sigma^2/n = 4/10 = 0.4$.

16 El cociente de verosimilitudes $L(\theta_1; x)/L(\theta_0; x)$.

17 Una χ^2 (teorema de Wilks).

18 La distribución muestral del estadístico.

19 El sesgo y la varianza, dejando un dato fuera a la vez.

20 $1 - \beta = 0.80$.