

PROFEVIXO • GUÍA DE ESTUDIO

Estadística descriptiva e inferencial

Muestreo, estimación y pruebas de hipótesis.

Probabilidad y estadística

Univ 1-3

20 EJERCICIOS

TEORÍA + RESULTADOS

Estadística descriptiva e inferencial

Área: Probabilidad y estadística · **Nivel:** Univ 1–3

Descripción: Muestreo, estimación y pruebas de hipótesis.

La estadística se divide en **descriptiva** (resume y presenta datos) e **inferencial** (generaliza de la muestra a la población con una medida de incertidumbre). Este material recorre ambas partes y sus herramientas básicas.

Población, muestra y datos

La **población** es el conjunto completo de unidades de interés. La **muestra** es el subconjunto observado, y debe obtenerse mediante **muestreo probabilístico** para ser representativa.

- **Parámetro:** valor que describe la población (μ, σ, p).
- **Estadístico:** valor que describe la muestra ($\bar{x}, s, \hat{p}$).
- **Unidad de análisis:** el individuo u objeto medido.

Tipos de datos

- **Cualitativos:** nominales (categorías sin orden) y ordinales (con orden).
- **Cuantitativos:** discretos (conteos) y continuos (mediciones).

Tipos de muestreo

- 1 **Aleatorio simple:** cada unidad tiene la misma probabilidad de ser elegida.
- 2 **Estratificado:** se divide la población en estratos homogéneos y se muestrea cada uno.
- 3 **Por conglomerados:** se eligen grupos completos y se estudian todos sus elementos.
- 4 **Sistemático:** se elige un punto de partida y un salto fijo k .

Mini-ejemplo. Para estudiar el ingreso de una ciudad, se divide por distritos (estratos) y se toma una muestra aleatoria dentro de cada distrito. Este diseño reduce la varianza frente al muestreo aleatorio simple.

Sesgo de selección. Ocurre cuando la muestra no representa a la población (por ejemplo, encuestas telefónicas que excluyen a quienes no tienen teléfono). Es el error más grave porque no desaparece al aumentar n .

Estadística descriptiva

Resume un conjunto de datos con medidas de centro, dispersión y forma.

Tendencia central

- **Media:** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.
- **Mediana:** valor central con los datos ordenados.
- **Moda:** valor más frecuente.

Dispersión

- **Rango:** $\max(x_i) - \min(x_i)$.
- **Varianza muestral:** $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.
- **Desviación estándar:** $s = \sqrt{s^2}$.
- **Rango intercuartílico:** $IQR = Q_3 - Q_1$.
- **Coefficiente de variación:** $CV = \frac{s}{\bar{x}}$.

Posición y forma

- **Cuartiles y percentiles:** dividen los datos ordenados.
- **Puntuación z :** $z = \frac{x - \bar{x}}{s}$, indica cuántas desviaciones estándar dista un valor.
- **Asimetría y curtosis:** describen la forma de la distribución.

Mini-ejemplo. Para los datos 2, 4, 4, 5, 9: media 4.8, mediana 4, moda 4, varianza $s^2 = 6.7$. La **mediana** y el IQR son **robustos** ante valores atípicos; la media y la desviación estándar no lo son.

Distribuciones muestrales

La **distribución muestral** de un estadístico es su distribución sobre todas las muestras posibles de tamaño n .

Propiedades de la media muestral $\bar{X}$:

- $E[\bar{X}] = \mu$ (insesgada).
- $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$.
- **Error estándar:** $SE = \frac{\sigma}{\sqrt{n}}$.
- Si la población es normal, $\bar{X}$ es normal para cualquier n .
- Si no es normal, el **teorema central del límite** garantiza normalidad aproximada cuando n es grande.

Para la proporción muestral $\hat{p}$:

$$SE = \sqrt{\frac{p(1-p)}{n}}$$

Factor de corrección por población finita: si la muestra es grande respecto a la población,

$$SE = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

Mini-ejemplo. Con $\sigma = 10$ y $n = 100$ el error estándar es 1: las medias muestrales varían mucho menos que los individuos de la población.

Estimación e intervalos de confianza

Un **estimador puntual** es un estadístico usado para aproximar un parámetro; una **estimación** es su valor observado en la muestra.

Un **intervalo de confianza (IC)** al nivel $1 - \alpha$ cuantifica la precisión de la estimación.

Media con σ conocida

$$\bar{x} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Al 95%, $z_{0.975} = 1.96$:

$$\bar{x} \pm 1.96 \frac{\sigma}{\sqrt{n}}$$

Media con σ desconocida

Se usa s y la **distribución t de Student** con $n - 1$ grados de libertad:

$$\bar{x} \pm t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}}$$

El multiplicador t es mayor que z , lo que refleja la incertidumbre adicional por estimar σ .

Proporción

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Tamaño de muestra

Para un margen de error deseado E :

$$n = \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2$$

Mini-ejemplo. Con $\bar{x} = 50$, $s = 10$ y $n = 25$ (t con 24 gl, $t = 2.064$):

$$IC_{95\%} = 50 \pm 2.064 \cdot 2 = [45.872, 54.128]$$

Interpretación correcta. El 95% de los intervalos contruidos así contienen al parámetro. No significa "probabilidad de que μ esté dentro del intervalo" una vez calculado, en el enfoque frecuentista.

Pruebas de hipótesis y valor p

Una **prueba de hipótesis** decide entre dos afirmaciones sobre la población.

- H_0 (**hipótesis nula**): afirmación de referencia (sin efecto, sin diferencia).
- H_1 (**hipótesis alternativa**): lo que se busca evidencia a favor.

Pasos

- 1 Formular H_0 y H_1 (una o dos colas).
- 2 Elegir el nivel de significancia α (típicamente 0.05).
- 3 Seleccionar el estadístico y verificar sus supuestos.
- 4 Calcular el estadístico y el **valor p**.
- 5 Decidir: si $p < \alpha$, se rechaza H_0 ; en caso contrario, no se rechaza.

Errores y potencia

Decisión	H_0 verdadera	H_0 falsa
No rechazar H_0	Acierto	Error tipo II (β)
Rechazar H_0	Error tipo I (α)	Acierto (potencia $1 - \beta$)

El **valor p** es la probabilidad de observar un resultado al menos tan extremo como el obtenido, suponiendo que H_0 es verdadera. **No** es la probabilidad de que H_0 sea cierta.

Mini-ejemplo (z para una media). Con $\bar{x} = 52$, $\mu_0 = 50$, $\sigma = 10$ y $n = 25$:

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{2}{2} = 1, \quad p \approx 0.317$$

No hay evidencia suficiente para rechazar H_0 al 5%.

Pruebas t, chi-cuadrado y ANOVA

Prueba t de una muestra

Cuando σ es desconocida:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

Prueba t de dos muestras

- **Independientes (varianzas iguales):** $t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$, con $s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$.
- **Pareadas:** se trabaja con las diferencias d_i y $t = \frac{\bar{d}}{s_d/\sqrt{n}}$.
- **Muestras grandes o varianzas desiguales:** corrección de Welch.

Chi-cuadrado (χ^2)

- **Bondad de ajuste:** $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$, con $k - 1$ grados de libertad.
- **Independencia en tablas de contingencia:** $gl = (r - 1)(c - 1)$.

ANOVA de un factor

Compara las medias de k grupos:

$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad dentro de grupos}}$$

Con F grande se rechaza la igualdad de medias. Los grados de libertad son $k - 1$ (entre) y $n - k$ (dentro).

Alternativas no paramétricas

Wilcoxon, Mann-Whitney y Kruskal-Wallis no requieren normalidad.

Mini-ejemplo. Para comparar un medicamento con un placebo se usa una prueba t de dos muestras; si $p < 0.05$, se concluye diferencia significativa.

Advertencia. Hacer muchas pruebas infla el error tipo I; se corrige con Bonferroni (α/m) o con control de la tasa de falsos descubrimientos (FDR).

Correlación y regresión lineal

Correlación de Pearson

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \in [-1, 1]$$

Mide la fuerza y el sentido de la asociación **lineal**. $r = 0$ no implica ausencia de relación, solo de relación lineal.

Regresión lineal simple

$$\hat{y} = b_0 + b_1 x, \quad b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad b_0 = \bar{y} - b_1 \bar{x}$$

Bondad de ajuste

$$R^2 = r^2$$

es la proporción de la varianza de y explicada por x .

Supuestos

- 1 Linealidad.
- 2 Independencia de los errores.
- 3 **Homocedasticidad** (varianza constante).
- 4 Normalidad de los residuos.

Mini-ejemplo. Años de estudio vs salario con $b_1 \approx 2000$ significa que cada año adicional se asocia, en promedio, con $\approx 2000\$$ más de salario. Es una **asociación**, no una relación causal.

Ejercicios (20)

Nivel 1 · Descriptiva

- 1 Calcula la media de 3, 7, 7, 9, 14.
- 2 Calcula la mediana de 3, 7, 7, 9, 14.
- 3 Calcula la varianza muestral s^2 de 3, 7, 7, 9, 14.

4 Halla la moda de 3, 7, 7, 9, 14.

5 Halla el rango de 3, 7, 7, 9, 14.

Nivel 2 · Intervalos y error estándar

6 Construye el IC al 95% para la media con $\bar{x} = 30$, $\sigma = 5$, $n = 100$.

7 Construye el IC al 95% para la media con $\bar{x} = 100$, $\sigma = 20$, $n = 25$.

8 Construye el IC al 95% para la proporción con $\hat{p} = 0.4$ y $n = 400$.

9 Calcula el error estándar de la media con $\sigma = 9$ y $n = 81$.

10 Halla el tamaño de muestra para un margen $E = 1$ con $\sigma = 8$ al 95%.

Nivel 3 · Pruebas y correlación

11 Prueba z : $\bar{x} = 54$, $\mu_0 = 50$, $\sigma = 12$, $n = 36$. Calcula z .

12 Halla el valor p de dos colas para $z = 2$.

13 Prueba t : $\bar{x} = 52$, $\mu_0 = 50$, $s = 6$, $n = 9$. Calcula t .

14 Calcula la correlación r de $(1, 3)$, $(2, 5)$, $(3, 9)$.

15 Halla la pendiente b_1 de la regresión para los datos del ejercicio 14.

Nivel 4 · Aplicaciones

16 Bondad de ajuste: frecuencias observadas 10, 20, 30, 40 con esperadas 25 en cada una. Calcula χ^2 .

17 ¿Cuántos grados de libertad tiene una prueba χ^2 de independencia en una tabla 3×4 ?

18 En un ANOVA con $k = 4$ grupos y $n = 20$ observaciones, ¿cuántos grados de libertad tiene el numerador (F_{entre})?

19 Prueba t pareada: $\bar{d} = 2$, $s_d = 5$, $n = 25$. Calcula t .

20 Si $r = 0.9$, ¿cuánto vale R^2 ?

Respuestas

1 $\bar{x} = 8.$

2 Mediana = 7.

3 $s^2 = 16.$

4 Moda = 7.

5 Rango = 11.

6 $IC = 30 \pm 0.98 = [29.02, 30.98].$

7 $IC = 100 \pm 7.84 = [92.16, 107.84].$

8 $IC = 0.4 \pm 0.048 = [0.352, 0.448].$

9 $SE = 1.$

10 $n = 245.86 \Rightarrow 246.$

11 $z = 2.$

12 $p \approx 0.0455.$

13 $t = 1.$

14 $r \approx 0.982.$

15 $b_1 = 3.$

16 $\chi^2 = 20.$

17 $gl = 6.$

18 $gl = 3.$

19 $t = 2.$

20 $R^2 = 0.81.$