

PROFEVIXO • GUÍA DE ESTUDIO

Series de tiempo

Tendencia, estacionalidad y modelos ARIMA.

Probabilidad y estadística

Univ 4-5

20 EJERCICIOS

TEORÍA + RESULTADOS

Series de tiempo

Componentes de una serie de tiempo

Una **serie de tiempo** es una secuencia de observaciones ordenadas en el tiempo, $\{y_t\}_{t=1}^n$, donde el orden importa. Sus componentes clásicas son:

- 1 **Tendencia** T_t : movimiento de largo plazo (crecimiento, declive o estancamiento).
- 2 **Estacionalidad** S_t : patrón que se repite con un periodo fijo s (diario, semanal, mensual, anual).
- 3 **Ciclo** C_t : fluctuación larga e irregular, sin periodo fijo (ciclos económicos).
- 4 **Ruido** ε_t : variación residual aleatoria no explicada.

Composición. El modelo **aditivo** supone que las componentes se suman:

$$y_t = T_t + S_t + C_t + \varepsilon_t$$

y es apropiado cuando la amplitud estacional es aproximadamente constante. El modelo **multiplicativo** supone que se multiplican:

$$y_t = T_t \cdot S_t \cdot C_t \cdot \varepsilon_t$$

y es apropiado cuando la amplitud estacional crece con el nivel de la serie. El logaritmo convierte un modelo multiplicativo en aditivo: $\ln y_t = \ln T_t + \ln S_t + \ln C_t + \ln \varepsilon_t$.

Mini-ejemplo. Las ventas minoristas de diciembre suelen combinar una tendencia creciente con un pico estacional pronunciado y ruido. Si el pico crece cada año en términos absolutos, conviene el esquema multiplicativo.

Descomposición. En la práctica cada componente se estima con medias móviles o con el método **STL** (*Seasonal-Trend decomposition using Loess*), que separa tendencia, estacionalidad y resto de forma iterativa.

Estacionariedad y diferenciación

Una serie es **débilmente estacionaria** (o estacionaria en sentido amplio) si:

- 1 $E[y_t] = \mu$ constante para todo t .
- 2 $\text{Var}(y_t) = \gamma_0$ constante para todo t .

3 $\text{Cov}(y_t, y_{t+h}) = \gamma_h$ depende solo del rezago h , no de t .

Una serie **estrictamente estacionaria** requiere que toda la distribución conjunta sea invariante al desplazamiento temporal; la versión débil solo fija los dos primeros momentos.

Por qué importa. Los modelos ARMA y ARIMA necesitan estacionariedad (o una versión diferenciada de ella) para que los coeficientes tengan interpretación estable y la inferencia sea válida. Sin estacionariedad aparecen **regresiones espurias**.

Operador de rezago. Con $Ly_t = y_{t-1}$, la primera diferencia es

$$\Delta y_t = y_t - y_{t-1} = (1 - L) y_t,$$

y la diferencia de orden d es $\Delta^d y_t = (1 - L)^d y_t$. La **diferencia estacional** de periodo s es

$$\Delta_s y_t = y_t - y_{t-s} = (1 - L^s) y_t.$$

Transformaciones útiles.

1 **Diferenciación** Δy_t : elimina tendencia (raíz unitaria).

2 **Logaritmo** $\ln y_t$: estabiliza varianza que crece con el nivel.

3 **Diferencia estacional** $\Delta_s y_t$: elimina el patrón estacional determinista o estocástico.

4 **Box-Cox** $y_t^{(\lambda)} = \frac{y_t^\lambda - 1}{\lambda}$: familia que incluye logaritmo ($\lambda \rightarrow 0$).

Mini-ejemplo. El paseo aleatorio $y_t = y_{t-1} + \varepsilon_t$ no es estacionario: $\text{Var}(y_t) = t \sigma_\varepsilon^2$ crece con t . Su primera diferencia $\Delta y_t = \varepsilon_t$ sí es estacionaria.

Pruebas. La **Dickey-Fuller aumentada (ADF)** contrasta H_0 : existe raíz unitaria (no estacionaria). El **KPSS** contrasta la hipótesis opuesta (H_0 : estacionariedad), por lo que conviene usar ambas.

Autocorrelación: ACF y PACF

La **función de autocorrelación (ACF)** mide la correlación lineal de la serie con sus propios rezagos:

$$\rho_h = \frac{\gamma_h}{\gamma_0} = \frac{\text{Cov}(y_t, y_{t+h})}{\text{Var}(y_t)}, \quad \rho_0 = 1, \quad -1 \leq \rho_h \leq 1.$$

La **autocorrelación parcial (PACF)** mide la correlación de y_t con y_{t+h} **descontando** el efecto de los rezagos intermedios $y_{t+1}, \dots, y_{t+h-1}$. Es el último coeficiente de una regresión de y_t sobre $y_{t-1}, \dots, y_{t-h}$.

Regla de identificación.

- 1 Un modelo **AR(p)** tiene ACF que decae gradualmente (cola infinita) y PACF que **corta** en el rezago p .
- 2 Un modelo **MA(q)** tiene ACF que **corta** en el rezago q y PACF que decae gradualmente.
- 3 Un modelo **ARMA(p, q)** tiene ACF y PACF que decaen ambas gradualmente.

Bandas de confianza. Bajo ruido blanco, ρ_h es aproximadamente normal con desviación $1/\sqrt{n}$, de modo que valores fuera de $\pm 1.96/\sqrt{n}$ se consideran significativos.

Mini-ejemplo. Si la PACF es significativa en el rezago 1 y nula después, mientras la ACF decae suavemente, un AR(1) es el candidato natural. Si la ACF es significativa en los rezagos 1 y 2 y luego nula, se sugiere un MA(2).

Modelos AR, MA y ARMA

Autorregresivo AR(p). El valor actual depende de valores pasados:

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t.$$

Es estacionario si las raíces del polinomio característico $1 - \phi_1 z - \dots - \phi_p z^p = 0$ están **fuera** del círculo unitario ($|z| > 1$). En el caso AR(1), la condición se reduce a $|\phi_1| < 1$, y la media es $\mu = c/(1 - \phi_1)$.

Medias móviles MA(q). El valor actual depende de errores pasados:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

Todo MA es estacionario; es **invertible** si las raíces de $1 + \theta_1 z + \dots + \theta_q z^q = 0$ están fuera del círculo unitario.

ARMA(p, q). Combina ambas estructuras:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Si se cumple estacionariedad e invertibilidad, el modelo admite una representación AR(∞) y otra MA(∞).

Mini-ejemplo (AR(1)). Con $\phi = 0.7$ la ACF es $\rho_h = 0.7^h$, que decae geométricamente; la varianza estacionaria es $\frac{\sigma_\varepsilon^2}{1 - \phi^2}$.

Mini-ejemplo (MA(1)). Con $\theta_1 = 0.5$ la ACF vale $\rho_1 = \frac{\theta_1}{1 + \theta_1^2} = 0.4$ y $\rho_h = 0$ para $h \geq 2$; la varianza es $(1 + \theta_1^2)\sigma_\varepsilon^2$.

ARIMA y SARIMA

ARIMA(p, d, q). Se aplica ARMA al resultado de diferenciar la serie d veces:

$$\Delta^d y_t = c + \sum_{i=1}^p \phi_i \Delta^d y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

El parámetro d maneja **tendencias estocásticas** (raíces unitarias). Si $d = 0$ se recupera un ARMA.

SARIMA(p, d, q)(P, D, Q) $_s$. Añade un bloque estacional de periodo s :

$$\phi_p(L) \Phi_P(L^s) (1 - L)^d (1 - L^s)^D y_t = \theta_q(L) \Theta_Q(L^s) \varepsilon_t,$$

donde Φ_P y Θ_Q son los polinomios estacionales y D el número de diferencias estacionales.

Metodología Box-Jenkins.

- 1 **Identificación:** transformar a estacionaria; examinar ACF/PACF para proponer p, d, q .
- 2 **Estimación:** ajustar los candidatos por máxima verosimilitud o mínimos cuadrados.
- 3 **Diagnóstico:** los residuos deben ser **ruido blanco**; usar ACF residual y el test de **Ljung-Box**.
- 4 **Pronóstico:** predecir y actualizar al llegar nueva información.

Criterios de selección. Se comparan modelos con **AIC** y **BIC**, penalizando el número de parámetros:

$$\text{AIC} = -2 \ln L + 2k, \quad \text{BIC} = -2 \ln L + k \ln n.$$

Mini-ejemplo. Ventas mensuales con tendencia y estacionalidad anual sugieren un SARIMA(1, 1, 0)(1, 1, 0) $_{12}$.

Suavizado exponencial

Alternativa simple y robusta a ARIMA para pronosticar.

Suavizado exponencial simple (SES). Para series sin tendencia:

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t, \quad 0 < \alpha < 1.$$

El parámetro α controla la memoria: valores cercanos a 1 dan más peso al dato reciente.

Método de Holt. Añade una componente de tendencia b_t :

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \quad b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1},$$

$$\hat{y}_{t+h} = \ell_t + h b_t.$$

Holt-Winters. Añade estacionalidad de periodo s , en versión **aditiva** o **multiplicativa**:

$$\hat{y}_{t+h} = \ell_t + h b_t + s_{t+h-s}, \quad (\text{aditiva}).$$

Mini-ejemplo. Con $\alpha = 0.4$, $y_t = 20$ y $\hat{y}_t = 15$ se obtiene $\hat{y}_{t+1} = 0.4(20) + 0.6(15) = 17$.

Ventaja: fácil de automatizar y estable con pocos datos. **Desventaja:** menor fundamento inferencial y no ofrece intervalos tan naturales como ARIMA.

Volatilidad: ARCH y GARCH

En finanzas la varianza **cambia** con el tiempo (**heterocedasticidad condicional**). Un modelo **ARCH(q)** describe la varianza condicional como función de errores pasados al cuadrado:

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \cdots + \alpha_q \varepsilon_{t-q}^2, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1).$$

GARCH(p, q) añade las varianzas pasadas:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2.$$

Propiedades. GARCH(1,1) es estacionario en covarianza si $\alpha_1 + \beta_1 < 1$; la **persistencia** de la volatilidad es $\alpha_1 + \beta_1$. La varianza incondicional es $\bar{\sigma}^2 = \frac{\omega}{1 - \alpha_1 - \beta_1}$.

Hechos estilizados. Los **clusters de volatilidad** (días turbulentos se agrupan) y la asimetría (efecto apalancamiento, capturado por EGARCH o GJR-GARCH).

Mini-ejemplo. Tras un día de gran caída, un GARCH(1,1) predice mayor volatilidad mañana: la varianza tiene memoria. Con $\alpha_1 = 0.1$ y $\beta_1 = 0.8$, la persistencia es 0.9.

Validación y métricas de pronóstico

Partición temporal. Nunca se entrena con datos futuros: la muestra se divide en **train** (pasado) y **test** (futuro) respetando el orden cronológico.

Validación cruzada temporal. Dos esquemas habituales:

1 **Ventana expansiva** (*expanding*): el conjunto de entrenamiento crece con el tiempo.

2 **Ventana deslizante** (*rolling*): tamaño de entrenamiento fijo que avanza.

3 **Walk-forward:** reentrenar en cada paso simula el uso real y evita resultados inflados.

Métricas.

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2},$$

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|.$$

El **RMSE** penaliza más los errores grandes; el **MAPE** es porcentual (no depende de la escala) pero se indetermina si $y_t = 0$.

Residuos. Deben comportarse como ruido blanco: sin autocorrelación significativa (ACF, Ljung-Box) y con media cero.

Referencia. Todo modelo debe superar a un **baseline ingenuo**: el último valor $\hat{y}_{t+1} = y_t$ o el valor estacional $\hat{y}_{t+1} = y_{t-s}$.

Mini-ejemplo. Si el modelo tiene $\text{RMSE} = 15$ y el ingenuo $\text{RMSE} = 25$, la mejora relativa es $(25 - 15)/25 = 40\%$.

Ejercicios (20)

Nivel 1: Conceptos básicos

- 1 Identifica la componente dominante: ventas de helados con un pico cada verano.
- 2 ¿Es estacionaria la serie $y_t = \varepsilon_t$ con ε_t ruido blanco?
- 3 Para el AR(1) $y_t = 2 + 0.6 y_{t-1} + \varepsilon_t$, halla la media de largo plazo.
- 4 Obtén la primera diferencia de $y_t = 4t + \varepsilon_t$.
- 5 ¿Cómo se escribe la diferencia estacional de una serie trimestral?

Nivel 2: ACF, PACF y estacionariedad

- 6 Para un MA(1) con $\theta_1 = 0.5$, calcula ρ_1 .
- 7 Para un AR(1) con $\phi_1 = 0.7$, calcula ρ_2 .
- 8 La PACF de una serie corta en el rezago 2 y su ACF decae gradualmente. ¿Qué modelo se sugiere?
- 9 Para un AR(1) con $\phi_1 = 0.5$ y $\sigma_\varepsilon^2 = 3$, calcula la varianza estacionaria.
- 10 Escribe la condición de estacionariedad de un AR(1).

Nivel 3: Pronóstico y métricas

- 11 Con el AR(1) $y_t = 1 + 0.5 y_{t-1} + \varepsilon_t$ y $y_t = 4$, pronostica $\hat{y}_{t+1}$.
- 12 Serie real 100, 110 y pronóstico 90, 121. Calcula el MAPE.
- 13 Errores de pronóstico 2, -2, 2, -2. Calcula el RMSE.
- 14 Suavizado exponencial simple con $\alpha = 0.4$, $y_t = 20$ y $\hat{y}_t = 15$. Calcula $\hat{y}_{t+1}$.
- 15 En un GARCH(1,1) con $\alpha_1 = 0.1$ y $\beta_1 = 0.8$, ¿cuál es la persistencia?

Nivel 4: Aplicación

- 16 Una serie muestra tendencia lineal creciente y raíz unitaria. ¿Qué orden d usarías en un ARIMA?
- 17 Ventas mensuales con estacionalidad anual. ¿Qué periodo estacional s usarías en un SARIMA?
- 18 ¿Cuál es la hipótesis nula de la prueba ADF?
- 19 ¿Por qué la validación temporal no debe mezclar datos pasados y futuros?
- 20 Un modelo logra $\text{RMSE} = 15$ frente a $\text{RMSE} = 25$ del baseline ingenuo. ¿Qué mejora relativa obtiene?

Respuestas

- 1 Estacionalidad.
- 2 Sí: media 0, varianza constante y autocovarianza nula para $h \geq 1$.
- 3 $\mu = \frac{2}{1 - 0.6} = 5$.
- 4 $\Delta y_t = 4 + \varepsilon_t - \varepsilon_{t-1}$.
- 5 $\Delta_4 y_t = y_t - y_{t-4}$.
- 6 $\rho_1 = \frac{0.5}{1 + 0.5^2} = 0.4$.
- 7 $\rho_2 = 0.7^2 = 0.49$.

8 Un AR(2).

$$9 \text{ Var} = \frac{3}{1 - 0.5^2} = 4.$$

$$10 |\phi_1| < 1.$$

$$11 \hat{y}_{t+1} = 1 + 0.5(4) = 3.$$

$$12 \text{MAPE} = \frac{1}{2}(10\% + 10\%) = 10\%.$$

$$13 \text{RMSE} = \sqrt{\frac{4+4+4+4}{4}} = 2.$$

$$14 \hat{y}_{t+1} = 0.4(20) + 0.6(15) = 17.$$

$$15 \alpha_1 + \beta_1 = 0.9.$$

$$16 d = 1.$$

$$17 s = 12.$$

18 Que la serie tiene raíz unitaria (no es estacionaria).

19 Porque el futuro no puede usarse para predecir el pasado; hacerlo infla artificialmente el desempeño.

$$20 \frac{25 - 15}{25} = 40\%.$$